

GLOBAL SOLUTION 2026 — SpaceTrain Energy

Custo energético do treinamento de uma rede neural simples para cenários espaciais e Terra-espaço

Disciplina: Computação Neuromórfica | Tecnologia em IA • Relatório técnico (prova de conceito)

Identificação do grupo

#	Integrante	Matrícula
1	Caio Santiago de Oliveira	RM559788
2	Felipe Sayeg	RM560366
3	Diogo Cedola	RM559797

1. Cenário de aplicação escolhido

Cenário: Sensor de uma estação lunar, marciana ou remota que monitora temperatura, radiação e poeira.

O grupo representa a equipe de Infraestrutura, Energia e Escalabilidade de uma estação autônoma em ambiente extremo, com manutenção rara e energia limitada por painéis solares e baterias. A estação monitora temperatura, radiação e poeira (além de comunicação e fornecimento de energia) e precisa classificar localmente se há risco crítico (1) ou operação normal (0). O cenário é relevante porque, em órbita, na Lua ou em Marte, cada joule importa e enviar dados brutos à Terra é caro, lento e sujeito a falhas. Por isso, decidir entre treinar na borda, em GPU, em cluster ou rever a arquitetura é, antes de tudo, uma decisão de energia e de movimento de dados — exatamente o que esta prova de conceito mede.

2. Tabela 1 — Resultados dos três jobs

Valores gerados pela execução do notebook fornecido (semente fixa **rng = 123**, divisão treino/teste 70/30, 210 amostras de treino). O dataset não foi alterado.

Job	Features	Épocas	Forwards	RAM	Registr.	ULA	Energia treino (pJ)	Acurácia teste
A — Edge espacial simples	2	8	1.680	15.120	20.160	25.200	10.029.600	0,944
B — Operação Terra-espaço	4	15	3.150	47.250	56.700	72.450	31.248.000	0,978
C — Escala ampliada	6	25	5.250	110.250	126.000	162.750	72.817.500	1,000

Decomposição da energia de treino por componente




Figura 1 — Decomposição da energia de treino. Em todos os jobs, os acessos à RAM concentram ~96–97% da energia.

3. Tabela 2 — Projeção de escala e decisão de infraestrutura

A projeção usa o custo médio por amostra e por época observado em cada job e o multiplica pelas amostras e épocas de cada escala. A classificação segue a tabela didática do enunciado.

Escala	Amostras	Épocas	Energia Job A (pJ)	Infra A	Energia Job B (pJ)	Infra B	Energia Job C (pJ)	Infra C
Protótipo didático	10.000	20	$1,19 \times 10^9$	Local	$1,98 \times 10^9$	Local	$2,77 \times 10^9$	Local
Operação regional	200.000	50	$5,97 \times 10^{10}$	GPU	$9,92 \times 10^{10}$	GPU	$1,39 \times 10^{11}$	GPU
Constelação global	10.000.000	100	$5,97 \times 10^{12}$	Cluster	$9,92 \times 10^{12}$	Cluster	$1,39 \times 10^{13}$	Cluster
Missão massiva	100.000.000	200	$1,19 \times 10^{14}$	Super/Neuro	$1,98 \times 10^{14}$	Super/Neuro	$2,77 \times 10^{14}$	Super/Neuro

Legenda Infra: Local = Máquina local ($\leq 10^{10}$ pJ); GPU = Workstation/GPU (10^{10} – 10^{12} pJ); Cluster = Cluster (10^{12} – 10^{14} pJ); Super/Neuro = Supercomputador ou revisão arquitetural/neuromórfica ($> 10^{14}$ pJ).




Figura 2 — Crescimento da energia por escala (eixo log) e limites de decisão de infraestrutura.

Tabela de classificação didática de infraestrutura (referência):

Energia estimada de treino	Decisão de infraestrutura
até 10^{10} pJ	Máquina local
de 10^{10} a 10^{12} pJ	Workstation / GPU
de 10^{12} a 10^{14} pJ	Cluster
acima de 10^{14} pJ	Supercomputador ou revisão arquitetural / neuromórfica

4. Respostas às perguntas obrigatórias

1. Qual cenário foi escolhido e por que é relevante?

Estação remota / lunar / marciana que monitora temperatura, radiação e poeira (detalhado na seção 1). É relevante porque ambientes espaciais têm energia escassa, manutenção difícil e comunicação cara, instável e com atraso — o que torna o custo de treinar e escalar o modelo um fator de projeto tão importante quanto a acurácia.

2. Qual job consumiu mais energia? Explique com features, épocas, RAM, registradores e ULA.

O **Job C (Escala ampliada)** — **72.817.500 pJ**, contra 31.248.000 pJ do Job B e 10.029.600 pJ do Job A ($\approx 7,3 \times$ o Job A). O Job C combina os dois fatores de custo: tem mais **features (6 contra 4 e 2)**, o que aumenta o custo de cada amostra (mais leituras de pesos/feature na RAM, mais

multiplicações e somas na ULA), e mais **épocas (25 contra 15 e 8)**, o que multiplica o número de passagens. No código, por amostra a RAM cresce como $3 \cdot n + 3$ e a ULA como $4 \cdot n + 7$, e ambos são repetidos por (210 amostras $\times$ épocas) forwards. Assim o Job C lidera em RAM (110.250), registradores (126.000) e ULA (162.750) simultaneamente.

3. O aumento de energia está mais ligado a variáveis, épocas ou escala de amostras?

Entre os três jobs, **variáveis e épocas pesam de forma parecida**: de A para C as features triplicam ($2 \rightarrow 6$) e as épocas crescem $\sim 3,1 \times$ ($8 \rightarrow 25$), e a energia sobe $\sim 7,3 \times$ — aproximadamente o produto dos dois fatores. Porém, na projeção, quem domina de longe é a **escala de dados (amostras $\times$ épocas)**: do “Protótipo” (10.000×20) à “Missão massiva” ($100.000.000 \times 200$) o número de passagens cresce $\sim 100.000 \times$, e a energia cresce na mesma proporção (ex.: Job A vai de $1,19 \times 10^9$ para $1,19 \times 10^{14}$ pJ). Em resumo: no projeto do modelo, features e épocas importam; na operação real, a escala de amostras é o fator dominante.

4. Em qual escala a solução deixa de ser adequada para máquina local?

Na escala “**Operação regional**” (**200.000 amostras, 50 épocas**). No “Protótipo didático” os três jobs ficam em $\sim 10^9$ pJ ($\leq 10^{10} \rightarrow$ máquina local). Já na operação regional todos ultrapassam 10^{10} pJ ($5,97 \times 10^{10}$ a $1,39 \times 10^{11}$), saindo da faixa de máquina local e exigindo, no mínimo, workstation/GPU.

5. Em qual escala aparece a necessidade de workstation/GPU, cluster ou supercomputador?

Workstation/GPU surge na “Operação regional” (10^{10} – 10^{11} pJ); **Cluster** surge na “Constelação global” ($10M \times 100 \rightarrow 5,97 \times 10^{12}$ a $1,39 \times 10^{13}$ pJ); e **Supercomputador ou revisão neuromórfica** surge na “Missão massiva” ($100M \times 200 \rightarrow 1,19 \times 10^{14}$ a $2,77 \times 10^{14}$ pJ, acima de 10^{14}).

6. O gargalo está só na ULA ou também no movimento de dados?

Está claramente no **movimento de dados**, não na ULA. Pela fórmula, cada acesso à RAM custa 640 pJ contra apenas 10 pJ por operação da ULA ($64 \times$ mais). O resultado é que a RAM responde por **~ 96 – 97% da energia** em todos os jobs (no Job C: 70,56 milhões de pJ em RAM contra 1,63 milhão na ULA e 0,63 milhão em registradores), enquanto a ULA fica em $\sim 2\%$ e os registradores em $< 1\%$. É a manifestação direta do **gargalo de von Neumann**: o custo dominante é levar dados entre memória e processamento.

7. Que estratégia reduziria o custo sem perder a utilidade?

Combina **filtragem na borda** (treinar/transmitir só janelas anômalas, não todo o fluxo) com **redução de variáveis e épocas**. Os números justificam: o Job B já atinge 0,978 de acurácia com 4 features e 15 épocas; o Job C chega a 1,000 com 6 features e 25 épocas, mas custa $2,3 \times$ mais energia. Ou seja, o ganho marginal de ~ 2 pontos de acurácia mais que dobra a conta energética. Adotar uma configuração próxima do Job B (menos features, parada antecipada quando o ganho for pequeno) preserva quase toda a utilidade com uma fração do custo.

8. Apenas mais infraestrutura ou também revisão arquitetural?

As duas coisas, em momentos diferentes. Para escalas moderadas (regional a global), **mais infraestrutura** (GPU/cluster) resolve. Mas como $\sim 97\%$ da energia é movimento de dados, apenas “adicionar mais máquinas iguais” apenas replica a ineficiência. Para escala massiva, a alavanca real é **arquitetural**: processamento na borda/próximo do sensor para cortar o tráfego de dados e arquiteturas **neuromórficas / in-memory** que aproximam memória e processamento, atacando o gargalo de von Neumann na raiz.

5. Recomendação final de infraestrutura

Para o cenário de estação remota/lunar/marciana, recomenda-se uma estratégia escalonada: (a) no protótipo e em operações pequenas, manter treino e inferência na borda/máquina local com a configuração enxuta do Job A/B, pois a energia fica em $\sim 10^9$ pJ; (b) na operação regional, migrar para workstation/GPU; (c) na constelação global, usar cluster, aproveitando o paralelismo entre

múltiplas estações; (d) na missão massiva, em vez de partir direto para supercomputador, priorizar a revisão arquitetural — filtragem na borda e computação neuromórfica/in-memory — porque o custo é dominado por movimento de dados, e mais hardware do mesmo tipo escalaria a mesma ineficiência energética.

6. Estratégia de redução de custo energético

Estratégia escolhida: filtrar dados no sensor/borda antes do treinamento, somada à redução de variáveis e épocas. Na estação, a maioria dos minutos é operação normal (219 dos 300 registros têm risco 0), então treinar sobre tudo gasta energia com dados redundantes. Filtrar localmente — guardando e transmitindo apenas janelas com desvio relevante — reduz o número de amostras processadas, que é o fator que mais cresce em escala. Usar menos features e parada antecipada de épocas (o Job B atinge 0,978 de acurácia a um terço do custo do Job C) corta também o custo por amostra. Como o gargalo é o movimento de dados, reduzir o volume movimentado é a forma mais eficaz de baixar a energia.

7. Evidência de execução (Colab)

Print da execução final no Google Colab (última célula — resumo automático). Os valores impressos coincidem exatamente com as Tabelas 1 e 2 deste relatório. O notebook executado completo, com todas as saídas, é entregue junto a este relatório.



```
print("RESUMO PARA O RELATÓRIO")
print("-"*40)
for _, linha in resultado_job.iterrows():
    print(f"linha {linha['job']}: features={linha['n_features']}, épocas={linha['epocas']}, ram={linha['ram']}, Registradores={linha['registradores']}, ula={linha['ula']}, energia={linha['energia_treino_pj']:.0f} pJ, acurácia={linha['acuracia_teste']:.1f}")

print("Projeção de infraestrutura")
for _, linha in resultado_escala.iterrows():
    print(f"linha {linha['job']} | {linha['escala']} | energia={linha['energia_estimada_pj']:.2e} pJ | {linha['decisao_infraestrutura']}")
```

RESUMO PARA O RELATÓRIO

A - Edge espacial simples: features=42, épocas=8, ram=15120, Registradores=20160, ula=25200, energia=10029600 pJ, acurácia=0.944

B - Operação Terra-espaço: features=4, épocas=15, ram=7250, Registradores=46700, ula=72450, energia=3128000 pJ, acurácia=0.978

C - Escala ampliada: features=4, épocas=25, ram=120250, Registradores=120000, ula=162700, energia=72817500 pJ, acurácia=1.000

Projeção de infraestrutura:

A - Edge espacial simples | Protótipo didático | energia=1.19e+09 pJ | Máquina local

A - Edge espacial simples | Operação regional | energia=5.97e+10 pJ | Workstation/GPU

A - Edge espacial simples | Constelação global | energia=5.97e+12 pJ | Cluster

B - Operação Terra-espaço | Missão massiva | energia=1.19e+14 pJ | Supercomputador ou revisão arquitetural/neuromórfica

B - Operação Terra-espaço | Protótipo didático | energia=1.58e+09 pJ | Máquina local

B - Operação Terra-espaço | Operação regional | energia=5.92e+10 pJ | Workstation/GPU

B - Operação Terra-espaço | Constelação global | energia=5.92e+12 pJ | Cluster

C - Operação Terra-espaço | Missão massiva | energia=1.39e+14 pJ | Supercomputador ou revisão arquitetural/neuromórfica

C - Escala ampliada | Protótipo didático | energia=2.77e+10 pJ | Máquina local

C - Escala ampliada | Operação regional | energia=1.19e+11 pJ | Workstation/GPU

C - Escala ampliada | Constelação global | energia=1.19e+12 pJ | Cluster

C - Escala ampliada | Missão massiva | energia=2.77e+14 pJ | Supercomputador ou revisão arquitetural/neuromórfica

Figura 3 — Saída da última célula executada no Colab (resumo automático e projeção de infraestrutura).

Interpretação do grupo: lendo o resumo, confirmamos que o custo energético cresce de forma acentuada do Job A (10.029.600 pJ) ao Job C (72.817.500 pJ), acompanhando o aumento de features e épocas, enquanto a acurácia ganha pouco (0,944 → 1,000). Mais importante, o esforço é dominado pelos acessos à RAM — cerca de 97% da energia em todos os jobs —, e não pela ULA, o que evidencia o gargalo de von Neumann. A projeção mostra que, mantendo o mesmo modelo, a infraestrutura sobe de máquina local (protótipo) para workstation/GPU (operação regional), cluster (constelação global) e supercomputador/revisão neuromórfica (missão massiva). Para a nossa estação remota, isso reforça que o ponto crítico não é a conta aritmética, e sim o movimento de dados: controlar volume (filtragem na borda) e repetição (menos épocas) é o que mantém a solução viável à medida que a escala cresce.