

Global Solution 2026.1

Computação Quântica e IA — Indústria Espacial

QSVC & VQC aplicados à detecção de anomalias em telemetria de infraestrutura espacial

Um pipeline híbrido quântico-clássico para classificação de risco crítico em estações e satélites autônomos, com benchmarking justo contra modelos clássicos e análise crítica das limitações NISQ.

#	Integrante	RM
1	Caio Santiago de Oliveira	RM559788
2	Felipe Sayeg	RM560366
3	Diogo Cedola	RM559797

Turma	2TIAP(F-Y)-2026
Grupo	QuantumStation
ODS	9 (Indústria, inovação e infraestrutura) · 13 (Ação climática)
Stack	Python 3.10+ · Qiskit 1.2.4 · qiskit-machine-learning 0.8.2 · scikit-learn
Reprodutibilidade	random_state = 42 em todas as operações

Resumo executivo

Este trabalho implementa e avalia dois modelos de *Quantum Machine Learning* (QML) — um **QSVC** com *kernel* quântico de fidelidade e um **VQC** variacional — para detecção de anomalias em telemetria de infraestrutura espacial, classificando janelas de operação como *normal* ou *risco crítico*. Os modelos quânticos são comparados de forma justa contra dois baselines clássicos (SVM-RBF e Random Forest) sobre as mesmas *features*, o mesmo subconjunto de treino e o mesmo conjunto de teste. O pré-processamento segue um protocolo rigoroso — normalização para o intervalo $[-\pi, \pi]$, PCA com número de componentes igual ao número de qubits e ausência de *data leakage*. Os resultados mostram que, neste problema e no atual regime NISQ, os modelos clássicos superam amplamente os quânticos (AUC 0,93 contra 0,54-0,57), com custo computacional muito menor. O trabalho analisa criticamente as causas desse desfecho e o conecta ao estudo anterior do grupo em Computação Neuromórfica sobre custo computacional e energético.

1. Introdução e contexto espacial

O espaço deixou de ser um território exclusivamente científico para se tornar um ecossistema econômico em rápida expansão. Constelações de satélites monitoram o clima, orientam o agronegócio, conectam regiões remotas e antecipam desastres; programas como o Artemis estabelecem presença humana sustentável fora da Terra. Nesse cenário, a **manutenção autônoma da infraestrutura espacial** torna-se crítica: satélites e estações remotas precisam decidir localmente se estão em operação normal ou em risco, pois transmitir todo o fluxo de telemetria à Terra é caro, lento e sujeito a falhas de enlace.

Este projeto aborda exatamente esse problema — a **detecção de anomalias em telemetria** — como uma tarefa de classificação binária supervisionada (operação normal vs. risco crítico). A motivação para investigar *Quantum Machine Learning* nesse contexto é dupla. Primeiro, o QML é apontado como uma das fronteiras de arquiteturas computacionais alternativas. Segundo, este trabalho dá continuidade direta a um estudo anterior do grupo, na disciplina de Computação Neuromórfica, que mediu o custo energético do treinamento de redes para o mesmo cenário de estação remota e concluiu que cerca de 97% da energia é consumida no movimento de dados (gargalo de von Neumann), apontando que, em escala massiva, a alavanca real não é acrescentar mais máquinas iguais, mas **rever a arquitetura**. O presente trabalho pergunta: uma fronteira de decisão construída em um espaço de Hilbert (kernel quântico) seria uma dessas arquiteturas alternativas viáveis para a mesma classificação de risco?

Objetivos. (i) Construir um dataset de telemetria espacial fisicamente plausível; (ii) implementar QSVC e VQC em Qiskit 1.x; (iii) compará-los a baselines clássicos sob avaliação justa; (iv) analisar criticamente os resultados e as limitações NISQ; e (v) conectar a solução aos ODS 9 e 13.




Figura 1 — Arquitetura do pipeline híbrido quântico-clássico.

2. Descrição do dataset e pré-processamento

2.1 Natureza e dicionário de dados

O dataset representa a telemetria de uma estação/satélite autônomo em ambiente extremo (orbital, lunar ou marciano). Cada registro é uma janela de leitura dos sensores de bordo, rotulada quanto à presença de risco crítico. São **600 registros** (acima do mínimo de 500) com **duas classes**. Trata-se de um dataset sintético gerado por modelo físico com semente fixa, cujo pipeline é idêntico ao de um dataset real (p. ex. NASA POWER ou telemetria MSAD): basta substituir o arquivo de entrada.

Variável	Unid.	Descrição
temperatura_equip_c	°C	Temperatura do equipamento de bordo
radiacao_relativa	índice	Radiação relativa (eventos solares)
indice_poeira	0–1	Acúmulo de poeira sobre o painel solar
perda_comunicacao_pct	%	Perda de pacotes no enlace de comunicação
atraso_sinal_ms	ms	Latência do sinal Terra–estação
variacao_energia_pct	%	Variação de eficiência do painel solar

risco_critico	{0,1}	RÓTULO: normal (0) / risco crítico (1)
---------------	-------	--

Tabela 1 — Dicionário de dados.

2.2 Análise exploratória

As classes apresentam desbalanceamento moderado (cerca de 35% de registros de risco crítico), o que justifica a aplicação de SMOTE no conjunto de treino. Mais importante para a escolha do modelo quântico, os sensores são **fortemente correlacionados**: um mesmo evento de estresse ambiental eleva simultaneamente temperatura, radiação e poeira, degradando comunicação e energia. Observam-se correlações como 0,80 entre temperatura e poeira e $-0,76$ entre perda de comunicação e variação de energia. Essa estrutura de correlação de segunda ordem é o que fundamenta a escolha do ZZFeatureMap na etapa quântica.




Figura 2 — Distribuição de classes e matriz de correlação entre sensores.

2.3 Pré-processamento sem data leakage

O pré-processamento segue a ordem **split** → **imputação** → **PCA** → **escala**, com todos os estimadores ajustados (*fit*) **apenas no conjunto de treino** e aplicados (*transform*) ao teste — evitando vazamento de informação que invalidaria a avaliação. Os valores ausentes são tratados por imputação pela mediana; o PCA reduz as seis variáveis a quatro componentes (igual ao número de qubits); e a normalização usa MinMaxScaler para o intervalo $[-\pi, \pi]$, adequado à codificação em portas de rotação quânticas. O SMOTE balanceia somente o treino. O subconjunto de treino quântico é limitado a 300 amostras devido ao custo quadrático de simulação do kernel.




Figura 3 — Variância explicada pelo PCA. As quatro primeiras componentes retêm 99,9% da variância, muito acima do alvo de 70% — consequência direta da forte correlação entre sensores.

3. Implementação QML com Qiskit

3.1 Escolha do feature map

Adotou-se o **ZZFeatureMap** (reps=1, emaranhamento linear) como mapa de características. Diferentemente do **ZFeatureMap** — que codifica cada variável de forma independente — o **ZZFeatureMap** aplica rotações de fase de dois qubits, codificando explicitamente as **correlações de segunda ordem** entre as variáveis. Como demonstrado na análise exploratória, os sensores da estação são fortemente correlacionados, de modo que o **ZZFeatureMap** alinha-se à estrutura física do problema. Utilizam-se **4 qubits** (dentro da faixa NISQ recomendada de 3 a 5), correspondentes às quatro componentes do PCA.

3.2 QSVC com FidelityQuantumKernel

O QSVC emprega um *kernel* quântico baseado em fidelidade: a matriz de Gram é construída medindo a sobreposição entre os estados gerados pelo feature map para cada par de amostras, e essa matriz alimenta um SVM. A simulação utiliza o *sampler* de referência por *statevector* do Qiskit, garantindo reprodutibilidade exata. O notebook documenta a profundidade do circuito, o número de parâmetros e visualiza tanto o circuito (`qc.draw()`) quanto a matriz de kernel.

3.3 VQC com RealAmplitudes

O VQC treina um circuito parametrizado (ansatz **RealAmplitudes**, reps=2, emaranhamento linear) usando o otimizador **COBYLA** e perda de entropia cruzada. As medições são interpretadas por um mapeamento de paridade que produz um vetor de probabilidade, e a curva de convergência da função de perda é registrada por *callback*. O notebook reporta o ansatz, o número de parâmetros treináveis, a profundidade e o número de iterações.

Justificativa do tamanho do subconjunto. A simulação do kernel quântico exige da ordem de n^2 avaliações de circuito; treinar acima de algumas centenas de amostras torna-se proibitivo em simulador. Por isso fixou-se o treino quântico em 300 amostras, avaliando todos os modelos — quânticos e clássicos — no mesmo conjunto de teste, garantindo comparação justa.

4. Benchmarking e métricas

Treinamos dois baselines clássicos — **SVM-RBF** e **Random Forest** — sobre o mesmo subconjunto de treino dos modelos quânticos (300 amostras balanceadas) e avaliamos todos no mesmo conjunto de teste (180 amostras), com as métricas de avaliação. A Tabela 2 consolida os resultados.

Modelo	AUC	F1	Acur.	Prec.	Recall	Treino (s)	Infer. (ms)
QSVC (quântico)	0,541	0,431	0,517	0,367	0,524	162,81	1925,4
VQC (quântico)	0,572	0,465	0,528	0,385	0,587	86,86	5,54
SVM-RBF (clássico)	0,926	0,836	0,878	0,789	0,889	0,014	0,015
Random Forest (clás.)	0,907	0,800	0,856	0,776	0,825	0,343	0,123

Tabela 2 — Comparação consolidada. Os dois melhores modelos (clássicos) estão destacados. Tempo de inferência em ms por amostra.




Figura 4 — Curvas ROC sobrepostas. Os modelos clássicos (verde e vermelho) dominam o canto superior esquerdo; as curvas quânticas (azul e laranja) seguem próximas à diagonal de referência, indicando desempenho próximo ao aleatório.




Figura 5 — Matrizes de confusão normalizadas. Os modelos quânticos confundem amplamente as duas classes, enquanto os clássicos acertam a maioria dos casos de risco.

5. Análise dos resultados e conexão com o problema espacial

5.1 Interpretação do desempenho

Os resultados são claros e contrastantes: os modelos clássicos atingiram desempenho forte (SVM-RBF com AUC 0,926 e F1 0,836; Random Forest com AUC 0,907 e F1 0,800), enquanto os modelos quânticos ficaram muito aquém — QSVC com AUC 0,541 e VQC com AUC 0,572, ou seja, pouco acima do nível de um classificador aleatório (0,500). As matrizes de confusão e as curvas ROC confirmam esse quadro: as curvas quânticas praticamente acompanham a diagonal de referência.

Esse resultado, ainda que desfavorável ao QML, é legítimo e instrutivo. Algumas causas o explicam. Primeiro, o PCA concentrou a variância de forma extrema — a primeira componente já responde por 82,4% e as duas primeiras por 98,6% —, de modo que, das quatro dimensões codificadas nos quatro qubits, duas carregam quase nenhuma informação. O ZZFeatureMap mapeia essas quatro dimensões para o espaço de Hilbert, mas, com componentes quase nulas e poucas amostras, o kernel de fidelidade resultante torna-se pouco discriminativo: pares de amostras de classes diferentes acabam com sobreposição de estados semelhante à de pares da mesma classe. Segundo, no VQC, a curva de convergência (Figura 6) mostra a perda caindo de cerca de 1,30 e estagnando próximo de 0,99 a partir da iteração 50 — o otimizador COBYLA encontrou um platô que não separa bem as classes, comportamento compatível com regiões de gradiente achatado (*barren plateaus*) e com o limite de 80 iterações.




Figura 6 — Curva de convergência do VQC. A perda estabiliza em um platô elevado, sinalizando que o modelo variacional não conseguiu aprender uma fronteira de decisão eficaz.

Há ainda um aspecto de custo que não pode ser ignorado: o QSVC levou 162,8 s para treinar e, sobretudo, 1925 ms por amostra na inferência — cerca de cem mil vezes mais lento que o SVM clássico (0,015 ms). Para um sistema embarcado em satélite, com restrição severa de energia e tempo de resposta, essa diferença é, por si só, decisiva.

5.2 Limitações NISQ e ruído quântico

As limitações observadas conectam-se diretamente ao estado atual do hardware. **(i) Expressividade versus dados:** em regime NISQ, com poucos qubits e poucas amostras, o kernel quântico não capturou estrutura útil — e ainda penalizou o modelo com altíssimo custo. **(ii) Barren plateaus:** o platô na convergência do VQC ilustra a dificuldade de otimização variacional, agravada à medida que se aumentam qubits e profundidade. **(iii) Custo de simulação e ruído:** a simulação cresce de forma proibitiva (o kernel exige da ordem de n^2 avaliações de circuito), e em hardware real o ruído de portas e a decoerência degradariam ainda mais o resultado obtido no simulador ideal.

5.3 Conexão com o problema espacial e os ODS

A detecção de anomalias em telemetria sustenta a manutenção autônoma de satélites e estações remotas, onde decisões precisam ocorrer na borda. Isso conecta o trabalho ao **ODS 9** (infraestrutura resiliente e inovação tecnológica) e ao **ODS 13** (ação climática), já que a mesma telemetria alimenta o monitoramento ambiental orbital. À luz dos resultados, a conclusão prática é que, para este problema e neste estágio do hardware, a solução embarcável é a clássica — e isso prolonga, de forma coerente, o achado do projeto de Computação Neuromórfica do grupo: se o gargalo dominante é o movimento de dados e o custo computacional, uma arquitetura alternativa só se justifica quando entrega ganho real, o que o QML ainda não faz neste caso.

5.4 Roadmap de adoção

Curto prazo: adotar baselines clássicos embarcados (maduros, rápidos e baratos) para a triagem de anomalias na borda. **Médio prazo:** reservar o QML para investigação em problemas com correlação de alta ordem não redutível por PCA, ajustando feature maps e ansätze, e evitando a compressão agressiva de dimensionalidade que prejudicou o kernel aqui. **Longo prazo:** com hardware tolerante a falhas e algoritmos mais robustos a barren plateaus, reavaliar a vantagem quântica em larga escala.

6. Conclusões, limitações e próximos passos

Este trabalho entregou um pipeline híbrido quântico-clássico completo e reproduzível para detecção de anomalias em telemetria espacial, comparando QSVC e VQC a baselines clássicos sob avaliação justa. Os resultados foram conclusivos: neste problema e neste estágio de hardware, os modelos clássicos superaram amplamente os quânticos (AUC 0,93 contra 0,54-0,57), que ficaram próximos do nível aleatório, além de imporem custo computacional ordens de grandeza maior. Investigamos as causas —

concentração extrema da variância pelo PCA, kernel de fidelidade pouco discriminativo em regime NISQ e platô de convergência do VQC — e concluímos que, para a tarefa embarcada de detecção de risco, a solução clássica é a recomendada hoje. As principais limitações do estudo são o custo de simulação, a ausência de execução em hardware real e a sensibilidade do VQC à otimização. Como próximos passos, destacam-se: testar feature maps e ansätze alternativos, reduzir menos a dimensionalidade antes do encoding, incorporar um dataset real (NASA POWER ou telemetria MSAD) e, no futuro, reavaliar a vantagem quântica em hardware tolerante a falhas.

Referências

- [1] BIAMONTE, J. et al. Quantum machine learning. **Nature**, v. 549, p. 195–202, 2017.
- [2] HAVLÍČEK, V. et al. Supervised learning with quantum-enhanced feature spaces. **Nature**, v. 567, p. 209–212, 2019.
- [3] CEREZO, M. et al. Variational quantum algorithms. **Nature Reviews Physics**, v. 3, p. 625–644, 2021.
- [4] IBM QISKIT. **Qiskit Machine Learning Documentation**. 2024. Disponível em: <https://qiskit-community.github.io/qiskit-machine-learning/>. Acesso em: jun. 2026.
- [5] NASA. **National Aeronautics and Space Administration**. Disponível em: <https://www.nasa.gov>. Acesso em: jun. 2026.
- [6] NASA. **POWER Project — Meteorological and Solar Energy Data**. Disponível em: <https://power.larc.nasa.gov>. Acesso em: jun. 2026.
- [7] ESA. **European Space Agency**. Disponível em: <https://www.esa.int>. Acesso em: jun. 2026.
- [8] CHARTER, Space and Major Disasters. **International Charter**. Disponível em: <https://disasterscharter.org>. Acesso em: jun. 2026.